



UNIVERSIDADE FEDERAL DO CEARÁ - UFC
CENTRO DE TECNOLOGIA
DEPARTAMENTO DE TELEINFORMÁTICA

Homework 1

Disciplina: Estatística para Engenharia

Curso: Engenharia de Computação

Professora: Michela Mulas

Alunos: 1. Maria Paula Mesquita Silva Saraiva (Matrícula: 582204)
2. Cecília Fernandes Kalume (Matrícula: 590055)
3. Francisco Davi Moreira (Matrícula: 582887)
4. João Pedro de Castro Alves (Matrícula: 582929)

FORTALEZA
2026

Questão 1

Introdução

De modo geral, a questão se resume a carregar o arquivo `HW1_bike_sharing.csv` no ambiente R para construir o conjunto de dados desta atividade. Além disso, pede-se algumas operações simples, como a definição do maior valor entre as matrículas dos integrantes da equipe e a construção de um grupo amostral de 300 observações consecutivas, a partir da fórmula $r = 1 + (M \bmod 100)$.

Cálculo Teórico e Seleção da Amostra

Nesse raciocínio, os integrantes do grupo possuem as matrículas 582204, 590055, 582887 e 582929; sendo o maior valor $M = 590055$. Aplicando a relação matemática fornecida pelo enunciado $r = 1 + (M \bmod 100)$, temos:

$$r = 1 + (590055 \bmod 100) = 1 + 55 \Rightarrow r = 56$$

Validação dos Resultados no R e Descrição da Amostra

No ambiente R foi utilizada a função `"max()"` para determinação de M , o operador resto de divisão `"%%"` para o cálculo de r e a seleção do intervalo de linhas `"[r:(r + 299), ]"`. Os resultados computacionais convergiram com os cálculos teóricos ($r = 56$ e 300 amostras). Desse modo, a partir da linha $r = 56$ do arquivo original, foram extraídas as 300 observações consecutivas para compor o dataset `data_group`. O intervalo de dados abrange:

- **Data da primeira observação:** 25/02/2011 (`dteday[1]`)
- **Data da última observação:** 21/12/2011 (`dteday[300]`)

Por fim, a Tabela 1 sintetiza as principais propriedades da amostra `data_group` resultante, que servirá de base para as próximas análises.

Parâmetro / Propriedade	Valor Observado
Maior Matrícula (M)	590055
Linha Inicial (r)	56
Tamanho da Amostra	300 observações
Data da Primeira Observação	25/02/2011
Data da Última Observação	21/12/2011

Tabela 1: Resumo das propriedades do dataset do grupo (`data_group`).

Resolução Computacional

```
1 data_orig <- read.csv("HW1_bike_sharing.csv")
2 matriculas <- c(582204, 590055, 582887, 582929)
3 M <- max(matriculas)
4 r <- 1 + (M %% 100)
5
6 data_group <- data_orig[r:(r + 299), ]
7 data_group$dteday[1]
8 data_group$dteday[300]
```

Seleção e construção do dataset do grupo (`data_group`)

Questão 2

Em geral, esta questão tem como objetivo caracterizar as variáveis pertencentes ao conjunto de dados `data_group`, identificando suas classificações estatísticas, unidades de medida e a integridade da amostra. Além disso, define-se a variável `total_user`, definida pela soma do número de usuários casuais (`casual`) e registrados (`registered`), sobre a qual serão conduzidas as análises descritivas.

Item 2.1

Classificação e Descrição das Variáveis

O dataset `data_group` compreende 300 observações e 8 variáveis, incluindo a `total_user`. A classificação de cada variável, juntamente com sua unidade de medida e descrição, encontra-se estruturada a seguir:

- **Variáveis Categóricas (Qualitativas):**

- **instant (Qualitativa Ordinal):** É o índice sequencial do registro no *dataset* original. Embora seja representado por números inteiros, atua como um identificador das observações, indicando apenas a ordem de amostragem. Sendo, portanto, adimensional.
- **season (Qualitativa Ordinal):** Representa as quatro estações do ano no Hemisfério Norte, representadas de 1 a 4 (1: *Primavera*, 2: *Verão*, 3: *Outono* e 4: *Inverno*). É classificada como qualitativa ordinal, pois apesar de não haver hierarquia entre as estações, há uma ordem temporal cíclica entre elas, durante o ano.
- **weathersit (Qualitativa Ordinal):** Representa as condições meteorológicas do dia. É classificada como ordinal pois suas categorias seguem uma ordem de severidade do clima: 1: *Céu limpo*, 2: *Nublado*, 3: *Chuva fraca* e 4: *Chuva forte*.
- **dteday (Qualitativa Ordinal):** São as datas de cada observação no formato AAAA-MM-DD. Classifica-se como qualitativa ordinal pois serve para identificar cada dia, seguindo a ordem natural do calendário.

- **Variáveis Numéricas (Quantitativas):**

- **temp (Quantitativa Contínua):** Representa a temperatura diária registrada. É classificada como contínua, pois pode assumir qualquer valor decimal dentro de um intervalo contínuo. Unidade: °C
- **casual (Quantitativa Discreta):** Contagem do número de usuários casuais (não cadastrados) que utilizaram o sistema no dia. Unidade: *usuários/dia*.
- **registered (Quantitativa Discreta):** Contagem do número de usuários registrados que utilizaram o sistema no dia. Unidade: *usuários/dia*.
- **total_user (Quantitativa Discreta):** Número total de usuários por dia, calculado pela soma `casual + registered`. Unidade: *usuários/dia*.

Tipo Geral	Descrição do Tipo	Classificação	Definição da Classificação
Qualitativa	Representa atributos, categorias ou qualidades não numéricas.	Nominal	Categorias sem relação de ordem ou hierarquia entre si.
		Ordinal	Categorias que possuem uma ordenação ou escala lógica.
Quantitativa	Representa valores mensuráveis em escala numérica.	Discreta	Valores numéricos que são contáveis e inteiros.
		Contínua	Valores com medição contínua, ou seja, possuem parte decimal.

Tabela 2: Resumo e classificação das variáveis estatísticas.

Análise de Valores Ausentes

Foi verificado no R se havia alguma ausência de dados, por meio da função `colSums(is.na(data_group))`, que, a partir do comando `is.na()`, verifica cada elemento do *dataset*, retornando TRUE (1) para valores ausentes e FALSE (0) para valores preenchidos. Em seguida, a função `colSums()` realiza o somatório dessas ocorrências para cada variável (coluna). Assim, como o resultado obtido foi igual a zero para todas as colunas, confirmou-se a ausência de valores nulos ou faltantes no *dataset*.

Resolução Computacional

```
1 data_group$total_user <- data_group$casual + data_group$registered
2 colSums(is.na(data_group))
```

Item 2.1 - Criação da variável `total_user` e verificação de valores ausentes

Item 2.2

Cálculo das medidas de tendência central

O cálculo das medidas de tendência central são um passo importante dentro da estatística descritiva e facilitam o entendimento dos dados que possuímos, pois, como o nome sugere, **as medidas de tendência central** representam, por meio de um valor, um comportamento "central" ou típico de um conjunto de dados (o centro desse conjunto de dados).

- **Média:** Somando todos os valores do conjunto e dividindo-o pelo total de observações temos a média, que indica o valor do ponto de equilíbrio dos valores desse mesmo conjunto.
- **Mediana:** Representa o valor central do conjunto quando esse se encontra ordenado. Se houver uma quantidade ímpar de elementos, a mediana será o número da posição central do conjunto ordenado. Se a quantidade de elementos for par, a mediana será a média dos dois valores centrais.
- **Moda:** É o valor que mais se repete em um conjunto de dados. É especialmente importante para dados qualitativos, que, por serem rótulos e não números, não podem ser comparados numericamente, mas suas frequências podem.

Demonstração dos cálculos numa amostragem menor

Com o intuito de demonstrar como são realizados os cálculos da média, mediana e moda, foi assumida uma amostra das 10 primeiras observações do conjunto de dados amostral estudado:

	ID	Data	Estação	Condição	Temp °C	Casuais	Registrados	Totais
1	56	25/02/2011	Primavera	Nublado	14,9	120	1341	1461
2	57	26/02/2011	Primavera	Céu aberto	11,6	424	1545	1969
3	58	27/02/2011	Primavera	Céu aberto	14,1	694	1708	2402
4	59	28/02/2011	Primavera	Nublado	16,7	81	1365	1446
5	60	01/03/2011	Primavera	Céu aberto	10,9	137	1714	1851
6	61	02/03/2011	Primavera	Céu aberto	13,7	231	1903	2134
7	62	03/03/2011	Primavera	Céu aberto	8,1	123	1562	1685
8	63	04/03/2011	Primavera	Nublado	10,7	214	1730	1944
9	64	05/03/2011	Primavera	Nublado	15,8	640	1437	2077
10	65	06/03/2011	Primavera	Nublado	15,4	114	491	605

Tabela 3: Amostragem menor

Em seguida estão apresentadas as medidas de tendência central observadas a partir desses dados:

- **Cálculo da Média:** O cálculo da média é simples, se trata apenas da soma dos valores numéricos pela quantia de observações que temos desses dados.

- **Média da Temperatura:**

$$\frac{14,9 + 11,6 + 14,1 + 16,7 + 10,9 + 13,7 + 8,1 + 10,7 + 15,8 + 15,4}{10} = \frac{131,9}{10} = 13,19$$

- **Média de Usuários Casuais:**

$$\frac{120 + 424 + 694 + 81 + 137 + 231 + 123 + 214 + 640 + 114}{10} = \frac{2778}{10} = 277,8$$

- **Média de Usuários Registrados:**

$$\frac{1341 + 1545 + 1708 + 1365 + 1714 + 1903 + 1562 + 1730 + 1437 + 491}{10} = \frac{14796}{10} = 1479,6$$

- **Média de Usuários Totais:**

$$\frac{1461 + 1969 + 2402 + 1446 + 1851 + 2134 + 1685 + 1944 + 2077 + 605}{10} = \frac{17574}{10} = 1757,4$$

- **Cálculo da Mediana:** Em decorrência do conjunto de dados possuir 10 observações, o valor da mediana desses números será a média dos dois valores centrais, quando ordenados.

- **Mediana da temperatura:**

Ordenando os dados: 8, 1; 10, 7; 10, 9; 11, 6; 13, 7; 14, 1; 14, 9; 15, 4; 15, 8; 16, 7

Calculando a mediana:

$$\frac{13,7 + 14,1}{2} = \frac{27,8}{2} = 13,9$$

- **Mediana dos Usuários Casuais:**

Ordenando os dados: 81, 114, 120, 123, 137, 214, 231, 424, 640, 694

Calculando a mediana:

$$\frac{137 + 214}{2} = \frac{351}{2} = 175,5$$

- **Mediana dos Usuários Registrados:**

Ordenando os dados: 491, 1341, 1365, 1437, 1545, 1562, 1708, 1714, 1730, 1903

Calculando a mediana:

$$\frac{1545 + 1562}{2} = \frac{3107}{2} = 1553,5$$

- **Mediana dos Usuários Totais:**

Ordenando os dados: 605, 1446, 1461, 1685, 1851, 1944, 1969, 2077, 2134, 2402

Calculando a mediana:

$$\frac{1851 + 1944}{2} = \frac{3795}{2} = 1897,5$$

- **Cálculo da Moda:** O uso dessa medida de tendência central é distinto dos outros dois, por poder mostrar a centralidade de dados qualitativos, o que a torna extremamente útil. Sobre as demais aplicações da moda dentro do conjunto de dados estudado, as variáveis quantitativas descritivas presentes não possuem uma boa aplicabilidade de moda pelo tamanho do número e presença de muitos Algarismos Significativos, dificultando muito uma repetição. Essa mesma lógica é aplicável à temperatura, que é um valor quantitativo contínuo, e portanto são infinitos.

- **Moda da Estação:** Todas as 10 observações foram na primavera, sendo essa a moda.

- **Moda da Condição Meteorológica:** A moda da condição meteorológica é bimodal: céu aberto e nublado, ambos contando com 5 ocorrências.

Resolução Computacional

A partir do entendimento do cálculo manual das medidas de tendência central, pode-se aplicar esses métodos computacionalmente com o intuito de validar os resultados e de mostrar que o computador é confiável para a aplicação desses cálculos e permitir a aplicação do algoritmo na amostra maior.

- **Implementação:** O R já possui muitas das funções realizadas já diretamente implementadas na linguagem, a aplicação dessas funções estão a seguir:

- **Código da amostra:** O `data_groupinho` recebe as 10 primeiras observações de `/texttt-data_group`.

```
1 data_groupinho <- data_group[1:10, ]
```

- **Código da média:** Aplica-se a função `colMeans()` que recebe as colunas de número 6 até 9 (índices no R começam de 1), essas sendo temperatura (`temp`), usuários casuais (`casual`), usuários registrados (`registered`) e usuários totais (`total_user`), de `data_groupinho` e calcula a média em cada uma.

```
1 #media (sem na.rm pois ja nao tem dados ausentes, idem pros proximos)
2 colMeans(data_groupinho[, 6:9])
```

Código da média em `data_groupinho`

- **Código da mediana:** Aplica-se a função `median()` que calcula, uma coluna por vez, a mediana dos valores da coluna.

```
1 #mediana
2 median(data_groupinho$temp)
3 median(data_groupinho$casual)
4 median(data_groupinho$registered)
5 median(data_groupinho$total_user)
```

Código da mediana em `data_groupinho`

- **Código da moda:** Foi criada uma função que primeiro recebe uma coluna, em seguida com a função `table()` é aferido as repetições de cada valor com um nome atrelado (valor que possui tais repetições) e em seguida define o valor da moda como os nomes atrelados a maior frequência, permitindo então modas multimodais, pois se tiverem dois valores com a maior quantia de repetição ambos serão considerados como moda. A função também retorna a frequência da moda. Em seguida aplica-se a função ao valor das estações do ano e de condições climáticas.

```
1 #criando e usando moda
2 moda <- function(d){
3   freq <- table(d)
4   valor_moda <- names(freq)[freq == max(freq)]
5   freq_moda <- max(freq)
6
7   cat("Moda:", valor_moda, "\n")
8   cat("Frequencia:", freq_moda, "\n")
9 }
10
11 moda(data_groupinho$season)
12 moda(data_groupinho$weathersit)
```

Código de implementação da moda e uso em `data_groupinho`

- **Resultado e comparação:** Aplicando as funções implementadas anteriormente na amostra menor `data_groupinho` é obtido os seguintes dados:

Dado	Média	Mediana	Moda
Estação	N/A	N/A	Primavera
Condição	N/A	N/A	Céu aberto e Nublado (bimodal)
Temp °C	13,19	13,9	N/A
Casuais	277,80	175,5	N/A
Registrados	1479,60	1553,5	N/A
Totais	1757,40	1897,5	N/A

Tabela 4: Medidas de tendência central computacionais de `data_groupinho`.

Esses dados validam os cálculos manuais realizados anteriormente pois não há divergência, permitindo a aplicação segura do programa na amostra maior `data_group`:

Dado	Média	Mediana	Moda
Estação	N/A	N/A	Outono
Condição	N/A	N/A	Céu aberto
Temp °C	22,09867	22,2	N/A
Casuais	787,36667	692	N/A
Registrados	3026,79000	3238,5	N/A
Totais	3814,15667	4067,5	N/A

Tabela 5: Medidas de tendência central computacionais de `data_group`.

Discussão dos resultados

Pode-se observar, a partir dos resultados dos valores de medida de tendência central relacionados ao número de usuários: `casual` ; `registered` ; `total_user` que suas médias e medianas diferem. Tanto na análise do `data_groupinho` quanto na de `data_group` se vê que a média é visivelmente maior que a mediana, indicando uma possível distribuição assimétrica à direita (cauda de valores altos puxando a média para cima). O contrário ocorre com os usuários registrados e totais, sendo a média desses menor que a mediana e indicando uma distribuição assimétrica à esquerda, mostrando que os clientes casuais (sem registro) não alteram a tendência dos usuários totais de forma significativa, pois a magnitude de usuários registrados é muito maior. Pode ser observada também a imprecisão de trabalhar com amostras pequenas sem uma forma de distribuir a contagem, pois há uma grande diferença entre os valores de tendência central para condição do tempo meteorológico e da temperatura e dos valores de moda (moda da estação da amostra menor é primavera, mas ela só cobre 10 dias, enquanto a amostra maior se estende quase um ano inteiro e sua estação modal é o outono). Como a amostra menor cobre apenas um pequeno período do ano, ela não consegue abranger diferenças mais sutis do tempo pois há uma grande diferença entre os valores de tendência central para condição meteorológica e temperatura: A moda de `weathersit` muda de bimodal (céu aberto e nublado) para chuva fraca, e a temperatura média salta de $13.19^{\circ}C$ para $22.10^{\circ}C$. Como a amostra menor cobre apenas fevereiro e março de 2011, ela não consegue capturar a variação sazonal presente no restante do ano.

Item 2.3

Calculo dos Quartis Q1, Q2 e Q3

Os quartis são três valores que dividem um conjunto de dados ordenado em 4 partes. Esses valores são chamados de `Q1`, `Q2` e `Q3`, representando, respectivamente, a divisão em 25%, 50% e 75% dos dados.

Pela definição é possível perceber que $Q2$ se trata da mediana, ora, ambas são valores que apontam o centro de um vetor ordenado. Por isso, cálculo dos quartis se dá por meio do cálculo do $Q2$ (mediana) e a depender da paridade do número de observações, sendo uma das formas de calcular os quartis:

- Quando o número de observações é ímpar, a mediana ($Q2$) é um valor central e, para o cálculo de $Q1$ e $Q3$, esse valor central é desconsiderado, formando-se dois subconjuntos com a mesma quantidade de observações.
- Quando o número de observações é par, não existe uma única observação central. Nesse caso, $Q2$ é obtido pela média aritmética das duas observações centrais. As observações são então divididas igualmente em duas partes, sendo a metade inferior utilizada para determinar $Q1$ e a metade superior para determinar $Q3$.

Assim $Q1$ representa a mediana da metade inferior e $Q3$ representa a mediana da metade superior. Há também o intervalo interquartil, que se trata da diferença entre o terceiro quartil e o primeiro quartil, medindo assim a dispersão dos 50% centrais dentre as observações, sendo útil para ver a variação dos dados sem dados extremos (chamados outliers).

Demonstração do cálculo do quartil

A variável escolhida para o cálculo dos quartis foi a de usuarios totais, representada por `total_user` no código, para que seja analisado o número dos clientes do serviço. Os valores dessa variável na amostra de 10 observações será utilizada para mostrar na prática como são realizados os cálculos: Ordenando:

605, 1446, 1461, 1685, 1851, 1944, 1969, 2077, 2134, 2402

Como há um número par de observações, o $Q2$ será:

$$Q2 = \frac{1851 + 1944}{2} = \frac{3795}{2} = 1897,5$$

Também pela paridade, as observações serão divididas pela metade:

605, 1446, 1461, 1685, 1851

1944, 1969, 2077, 2134, 2402

Agora só resta aplicar o cálculo feito anteriormente, sabendo que ambos são ímpares então os quartis $Q1$ e $Q3$ serão os valores centrais:

$$Q1 = 1461$$

$$Q3 = 2077$$

A fim de aferir mais precisamente a variabilidade, excluindo os valores extremos, podemos calcular o intervalo interquartil $IIQ = Q3 - Q1$:

$$IIQ = 2077 - 1461 = 616$$

Resolução Computacional

Mostrados os cálculos de forma manual, é possível fazer uma comparação com o mesmo cálculo de quartis em um código na linguagem R, usando a função `quantile()`, que geral um quantil (número que divide as observações em partes iguais, quartis são um tipo de quantil que fazem a divisão em 4 partes. Se, por exemplo, for feita uma divisão das observações em 100 partes, elas seriam feitas por um conjunto de percentil) recebendo como parâmetros a amostra `data_groupinho` e um vetor `c(0.25, 0.5, 0.75)` que representam as divisões de um quartil.

```
1 #quartil Q1, Q2 e Q3
2 quartis_groupinho <- quantile(data_groupinho$total_user, probs = c(0.25, 0.5, 0.75))
```

Aplicação computacional do cálculo dos quartis

Aplicando essa função obtemos os seguintes resultados:

Q1	Q2	Q3
1517,0	1897,5	2050,0

Com os dados de Q1 e Q3 é possível calcular o intervalo interquartil com o seguinte código:

```
1 #intervalo interquartil
2 quartis_groupinho <- quantile(data_groupinho$total_user, probs = c(0.25, 0.5,
  0.75))
3 Q1 <- quartis_groupinho[1]
4 Q3 <- quartis_groupinho[3]
5 IIQ <- unname(Q3 - Q1)
6 IIQ
7 # alternativamente:
8 IQR(data_groupinho$total_user)
```

Aplicação computacional do cálculo do intervalo interquartil

Ambos resultando em um $IIQ = 533$

Percebe-se que houve uma discrepância entre os valores de $Q1$ e $Q3$ e da calculados anteriormente, isso se dá pois a função `quantile()` e a função `IQR()` em R usam um algoritmo diferente do que foi apresentado para o cálculo de quartis. Por padrão, o `quantile` usa o parâmetro `type = 7`, que se trata de calcular os quantis por meio da interpolação linear $q = (n - 1)p + 1$ em que q é o quantil, n o número de observações e p é a porcentagem da divisão. O fato de serem métodos diferentes e com resultados diferentes não os invalida. O método padrão da função será aplicado daqui em diante.

```
1 #quartil Q1, Q2 e Q3 no tipo usado manualmente (type=2)
2 quantile(data_groupinho$total_user, probs = c(0.25, 0.5, 0.75), type=2)
```

Q1	Q2	Q3
1461.0	1897.5	2077.0

e por sua vez `IQR` resulta em 616:

```
1 IQR(data_groupinho$total_user)
```

Amostra completa:

Expandindo para a amostra completa de 300 observações e aplicando a função definida anteriormente (apenas substituindo o `data_groupinho` por `data_group`):

```
1 quartis_group <- quantile(data_group$total_user, probs = c(0.25, 0.5, 0.75))
```

Resultados:

Q1	Q2	Q3
3116.5	4067.5	4681.0

Discussão dos resultados

Analisando os resultados dos quartis obtidos (lembrando que usamos o tipo 7, que é o tipo de cálculo de quartil padrão da linguagem R), é possível ver, tal qual no item anterior, que o intervalo interquartil da

amostra pequena ($IIQ = 533$) é menor que o da amostra maior ($IIQ = 1564.5$), sendo outra prova de que a amostra `data_groupinho`, que possui dados de apenas 10 dias consecutivos, a variação observada é limitada à variabilidade natural de poucos dias consecutivos da mesma estação. Já a amostra completa capta a variação real do sistema ao longo do ano. Por exemplo, dados sobre o aluguel nos dias de verão e nos de inverno não existem, ou seja, a variabilidade do aluguel dessas estações não aparecem. Vemos também que a distância entre $Q1$ e $Q2$ (mediana) e entre $Q2$ e $Q3$ em `casuais`, `registered` e `total_user`, mantém a mesma relação de desigualdade que a média e mediana do item passado, sendo outra forma de visualizar a assimetria à direita nos usuários casuais e assimetria à esquerda nos usuários registrados e totais. Também vê-se que, em termos de operação do sistema, o IIQ de 1564.5 usuários/dia na amostra completa pode ser lido como: em 50% dos dias do ano, a demanda por bicicletas varia, aproximadamente, entre 3117 e 4681 usuários (valor de $Q1$ e $Q3$).

Item 2.4

Construção dos gráficos histograma e boxplot

Até agora, se tem apenas as tabelas com os dados analisados, suas tendências de medida central e a análise de seus quartis. Também sabe-se que com essas informações já é possível entender, comparar e levantar conclusões importantes a respeito dos dados, assim como foi realizado nos itens anteriores. Entretanto há certa dificuldade em ler uma tabela cheia de linhas e colunas, principalmente se trabalhamos um amostras maiores. Para facilitar a compreensão desses dados é possível representá-los graficamente, de modo que seu entendimento seja de forma rápida e visual. O foco da representação é em dados numéricos (quantitativos) sendo uma ferramenta útil para a análise dos valores do item anterior. Dois tipos de representação gráfica serão aplicados no valor `total_user`:

- **Histograma:** O histograma mostra a frequência com que os valores de uma variável aparecem. Ele agrupa os dados em barras. Ele trabalha agrupando dados em intervalos chamados classes (bins), que geralmente são inseridos no eixo horizontal (barras ficam na vertical) e a altura dessa barra indica a frequência da quantidade de valores nesse intervalo.
- **Boxplot:** O boxplot mostra a distribuição, a dispersão e os valores discrepantes de um conjunto de dados numéricos. A representação em um boxplot é reconhecível pela presença de uma caixa e linhas indicando os maiores valores que não são outliers. Nela só importa um dos eixos, que é o eixo que indica o valor do dado. Ela é formada pelos seguintes componentes:
 - Mediana ($Q2$): Linha central da caixa, representando o valor do meio
 - Caixa (Box): A linha de topo e a de base da caixa são representadas pelo valor do primeiro quartil ($Q1$) até o terceiro quartil ($Q3$), ou seja, representa o intervalo interquartil ($IIQ = Q3 - Q1$), que contém os 50% centrais dos dados.
 - Bigodes (Whiskers): São as linhas saindo da caixa, se estendendo até os valores mínimos e máximos dentro de um determinado limite. Um dos possíveis cálculos para esse limite é: $Q1 - 1,5 \cdot IIQ$ e $Q3 + 1,5 \cdot IIQ$ que é o mesmo cálculo utilizado por funções em R.
 - Outliers: Qualquer valor além dos limites estabelecidos no cálculo dos whiskers é plotado individualmente como outlier.

A construção manual com a amostra menor envolveria o desenho do gráfico em si. Como o próprio gráfico desse exemplo seria construído computacionalmente a implementação em R é necessária. Para a plotagem dessa representação foi usada a biblioteca para R chamada de `ggplot2`. A construção gráfica se dará por meio da função `ggplot()` que receberá como parâmetro o grupo de dados `data_groupinho`, a função geometria do tipo desejado de representação e a função `labs()`, responsável por nomear elementos do gráfico. O `+` é usado em `ggplot()` para acrescentar essas funções como camadas visuais da função:

- **Código do Histograma:** No caso do histograma a função da sua geometria é `geom_histogram` e ela recebe em `mapping` qual dado ela deve usar para a plotagem (usando a função `aes()`, que indica um mapeamento estético), em `binwidth` o tamanho fixo do bin (intervalo da barra), em `bins` a quantia fixa de bins, em `fill` o preenchimento da barra (usando uma cor pinta-se a parte interna) e em `color` a cor da barra (usando o `fill` e o `color` em cores diferentes permite distinguir barras adjacentes). Os parâmetros escolhidos são vistos a seguir na implementação em código:

```

1 ggplot(data = data_groupinho) +
2   geom_histogram(mapping = aes(x = total_user), binwidth = NULL, bins = 30,
3     fill = "steelblue", color = "white") +
4   labs(
5     title = "Histograma do Valor de Clientes Totais",
6     x = "Valor de Clientes Totais",
7     y = "Frequencia"
8   )

```

O código resulta no seguinte histograma:




Figura 1: Histograma da variável total_user na amostra data_groupinho.

- **Código do Boxplot:** A geometria do boxplot é a função `geom_boxplot`, como parâmetros ele recebe o `mapping` para indicar qual dos valores calcular o boxplot e o `fill` e `color` como no item anterior. Os parâmetros escolhidos são vistos a seguir:

```

1 ggplot(data = data_groupinho) +
2   geom_boxplot(mapping = aes(y = total_user), fill = "steelblue", color = "
3     black") +
4   labs(
5     title = "Boxplot do Valor de Clientes Totais",
6     y = "Valor de Clientes Totais"
7   )

```

O código resulta no seguinte boxplot:




Figura 2: Boxplot da variável total_user na amostra data_groupinho.

É visível que a análise dos dados a partir das representações gráficas se torna mais simples que a interpretação de dados brutos em tabelas. Poder visualizar informações por meio de gráficos, diagramas e outros recursos visuais melhora significativamente essa compreensão. Como discutido anteriormente, ler e entender os gráficos de maneira muito mais rápida e fácil é muito importante dentro da área da estatística descritiva.

Resolução Computacional

Aplicando os códigos do assunto anterior para a amostra de 300 observações (data_group) da maneira a seguir, são obtidos os seguintes gráficos:

Histograma:

```
1 ggplot(data = data_group) +
2   geom_histogram(mapping = aes(x = total_user), binwidth = NULL, bins = 30, fill
3     = "steelblue", color = "white") +
4   labs(
5     title = "Histograma do Valor de Clientes Totais",
6     x = "Valor de Clientes Totais",
7     y = "Frequencia"
8   )
```




Figura 3: Histograma da variável total_user na amostra data_group.

Boxplot:

```
1 ggplot(data = data_group) +  
2   geom_boxplot(mapping = aes(y = total_user), fill = "steelblue", color = "black"  
3   ) +  
4   labs(  
5     title = "Boxplot do Valor de Clientes Totais",  
6     y = "Valor de Clientes Totais"  
7   )
```




Figura 4: Boxplot da variável `total_user` na amostra `data_group`.

Discussão dos resultados

Nos gráficos gerados da amostra `data_groupinho`, vemos que há a presença de valores *outliers* (representado pela coluna muito isolada de frequência 1 no histograma e pelo ponto do boxplot) e que há uma assimetria à esquerda, pois a moda (coluna com 2 de frequência no histograma), média (1757,40) e mediana (1897,5) se concentram à direita no histograma (e na parte superior do boxplot) e há uma cauda de valores menores que eles no lado oposto. É visível também que usar 30 bins no histograma com apenas 10 valores causa um problema em que os dados ficam dispersos no gráfico. A assimetria encontrada também foi observada nos itens anteriores dessa questão. Especificamente no boxplot, vê-se que a distância de $Q1$ a $Q2$ é muito maior que a distância de $Q2$ a $Q3$, mais uma vez indicando a assimetria.

Na visualização dos gráficos de `data_group`, o problema de poucos bins se resolve no histograma. No boxplot, com os limites máximos dos bigodes calculados através da fórmula da tolerância usada, $Q1 - 1,5 \cdot IIQ$ e $Q3 + 1,5 \cdot IIQ$, temos a presença de pontos, ou seja, valores *outliers*. O formato do histograma é consistente com a concentração da média (3814,15), da mediana (4067,5) e da moda no lado direito, sendo média ; mediana ; moda, portanto, uma distribuição assimétrica à esquerda. No boxplot chegamos à mesma conclusão, pois, assim como em `data_groupinho`, a distância de $Q1$ a $Q2$ é muito maior que a distância de $Q2$ a $Q3$.

Comparando as duas amostras, nota-se que a caixa do boxplot de `data_group` é visivelmente mais alta que a de `data_groupinho`, refletindo o aumento do intervalo interquartil observado no Item 2.3 (de 533 para 1564,5), esse é um reflexo direto da amostra maior abranger a variação de demanda ao longo do ano, e não apenas 10 dias consecutivos que são da mesma estação. Quanto aos *outliers*, os valores próximos de 600 até 800 usuários totais em ambos os boxplots ficam abaixo do limite inferior calculado ($Q1 - 1,5 \cdot IIQ \approx 769,75$ na amostra completa), condizendo com dias de demanda excepcionalmente baixa; plausivelmente associados a condições climáticas adversas ou feriados, hipótese que poderia ser confirmada consultando as variáveis `weathersit` e `dteday` desses dias específicos. De modo geral, a análise gráfica confirma visualmente a assimetria à esquerda e a maior variabilidade da amostra completa já identificadas nas medidas de tendência central e nos quartis, reforçando a limitação de generalizar conclusões com amostras pequenas e pouco representativas do período abrangido pelos dados estudados.

Item 2.5

1º quartil, número e proporção de dias de baixa utilização

No contexto do estudo estatístico do compartilhamento de bicicletas, também é importante ter conhecimento dos dados dos dias de baixa utilização desse sistema. Portanto, o procedimento deste item configura-se em calcular o primeiro quartil (Q_1) do número total de usuários (`total_user`) que o utilizaram diariamente, determinar o total de vezes e a proporção em que o número ficou abaixo do quartil.

Amostragem manual

Dessa forma, como abordado previamente no item 2.3, o primeiro quartil da amostra de 10 observações foi definido como:

$$Q_{1,\text{manual}} = x_{(3)} = 1461 \text{ usuários}$$

A partir disso, a variável `low_usage` dessa amostra é definida como:

$$\text{low_usage} = \begin{cases} 1, & \text{se } \text{total_user} < 1461 \\ 0, & \text{caso contrário} \end{cases}$$

Assim, na amostra de 10 dias, apenas 2 observações (605 e 1446) estiveram sob baixa utilização, o que resulta em uma proporção de 20% ($\frac{\text{número de vezes de baixa utilização}}{\text{total de observações}} = \frac{2}{10} = 0,20$).

Resolução Computacional

Ao aplicar a função `quantile()` do R à amostra de 10 dados (`data_groupinho`), obteve-se o valor de $Q_{1,\text{amostra}} = 1517$, como demonstrado no item 2.3. Apesar da diferença entre o quartil calculado manualmente e o do R, o resultado da variável `low_usage` manteve-se o mesmo, ou seja, 2 observações (20%) classificadas com baixa utilização.

```
1 Q1_amostra <- quantile(data_groupinho$total_user, 0.25)
2 data_groupinho$low_usage <- ifelse(data_groupinho$total_user < Q1_amostra, 1, 0)
3 baixa_util <- sum(data_groupinho$low_usage)
4 prop <- mean(data_groupinho$low_usage)
5
6 # Exibir resultados no console
7 Q1_amostra
8 baixa_util
9 prop
```

Cálculos para a amostra de 10 observações em R

Expandindo os cálculos para as 300 observações, obtivemos:

$$Q_1 = 3116,5 \text{ usuários}$$

Aplicando a regra de classificação de `low_usage` para o dataset:

$$\text{low_usage} = \begin{cases} 1, & \text{se } \text{total_user} < 3116,5 \\ 0, & \text{caso contrário} \end{cases}$$

O R retornou o total de 75 dias classificados como de baixa utilização (`low_usage = 1`). A proporção em relação ao período total foi calculada no R a partir da função `mean()`:

$$\text{Proporção} = \text{mean}(\text{low_usage}) = \frac{\text{soma total de } \text{low_usage}}{\text{total de observações}} = \frac{75}{300} = 0,25 \quad (25\%)$$

```
1 Q1 <- quantile(data_group$total_user, 0.25)
2 data_group$low_usage <- ifelse(data_group$total_user < Q1, 1, 0)
3 baixa_utilizacao <- sum(data_group$low_usage)
4 proporcao <- mean(data_group$low_usage)
```

```

5
6 # Exibir resultados no console
7 Q1
8 baixa_utilizacao
9 proporcao

```

Cálculos para o dataset de 300 observações

Explicação do critério no contexto dos dados

- O primeiro quartil ($Q_1 = 3116,5$ usuários) estabelece o limite dos 25% menores valores da distribuição, o que justifica o fato de 75 dias (25% de 300) serem classificados com $low_usage = 1$. Nesse contexto, tal parâmetro funciona como um limite para isolar dias de demanda atípica, permitindo relacionar a queda na utilização com fatores climáticos ou sazonais (**weathersit**, **season**, **temp**) e servir como base de decisões de gestão.

Questão 3

A questão tem como objetivo utilizar as variáveis **low_usage** e **total_user** para investigar como situações como tempo, temperatura e estação do ano afetam a utilização do sistema.

Fundamentação Teórica sobre desvio padrão

O desvio padrão é a raiz quadrada da variância, ou seja, é a raiz quadrada da média dos quadrados da diferença entre os termos e a média de um conjunto de dados podendo ser escrito como:

$$\sigma = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}}$$

Portanto, pela maneira que ele é calculado, percebe-se que ele é um meio para medir a dispersão de um grupo de dados ao mesmo tempo que mantém a unidade original do dado, já que, na variância, a unidade de medida de todos os dados é elevada ao quadrado, então, ao se tirar a raiz disso, preserva-se a unidade original.

Além disso, quando se calcula o desvio padrão amostral de um conjunto de dados a ideia geral de ser uma ferramenta para se calcular o grau de dispersão de um conjunto de dados e preservar a unidade dos dados se mantém, porém como ela é apenas um subconjunto da população total de dados, é necessário fazer um fator de correção para garantir que essa análise não seja enviesada, portanto, ao invés de fazer a média com n elementos, se faz com $n - 1$ elementos, assim como na fórmula abaixo:

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

Item 3.1

A questão pede para calcular a média, mediana e desvio padrão de **total_user** para cada estação do ano e, por meio do código presente no final do documento obtivemos como resultado as seguintes tabelas:

Estações	total_user
1	2045,760
2	3775,174
3	4464,362
4	3664,461

Tabela 6: Média do número total de usuários por estação.

Estações	total_user
1	2056,0
2	4085,5
3	4615,5
4	3717,0

Tabela 7: Mediana do número total de usuários por estação.

Estações	total_user
1	611,4175
2	1138,9010
3	798,3481
4	983,0061

Tabela 8: Desvio padrão do número total de usuários por estação.

Proporção de low_usage

Além disso, a questão também tem o objetivo de analisar a proporção de `low_usage` em cada estação. Desse modo, obtiveram-se duas tabelas: uma com a quantidade de `low_usage` em valores absolutos por estação e outra com os valores relativos.

Estações	low_usage (Valor Absoluto)
1	23
2	24
3	4
4	24

Tabela 9: Quantidade absoluta de `low_usage` por estação.

Estações	low_usage (Proporção Relativa)
1	0,92000000
2	0,26086957
3	0,04255319
4	0,26966292

Tabela 10: Proporção relativa de `low_usage` por estação.

Box plot:

O código para gerar um box plot a partir das estações e de `total_user` encontra-se ao final do documento, resultando no seguinte diagrama:




Figura 5: Boxplot da variável `total_user` por estação do ano.

Amostras

Para fazer as amostragens das estações do ano foram criados 4 data groups os quais são: `data_groupinho_season1`, `data_groupinho_season2`, `data_groupinho_season3` e `data_groupinho_season4` em que cada grupo possui as 10 primeiras ocorrências de cada estação do ano designada a ele.

MÉDIA:

Formula da media:

$$\bar{x} = \frac{\sum x}{n}$$

Para season1:

$$\bar{x} = \frac{1461 + 1969 + 2402 + 1446 + 1851 + 2134 + 1685 + 1944 + 2077 + 605}{10} = 1757.4$$

Para season2:

$$\bar{x} = \frac{2077 + 2703 + 2121 + 1865 + 2210 + 2496 + 1693 + 2028 + 2425 + 1536}{10} = 2115.4$$

Para season3:

$$\bar{x} = \frac{4835 + 4507 + 4790 + 4991 + 5202 + 5305 + 4708 + 4648 + 5225 + 5515}{10} = 4972.6$$

Para season4:

$$\bar{x} = \frac{2395 + 5423 + 5010 + 4630 + 4120 + 3907 + 4839 + 5202 + 2429 + 2918}{10} = 4087.3$$

MEDIANA

Como há um número par de elementos ($n = 10$), a mediana é calculada pela média dos elementos centrais:

$$\text{Mediana} = \frac{x_{(n/2)} + x_{(1+n/2)}}{2} = \frac{x_{(5)} + x_{(6)}}{2}$$

Para season1:

Posição	Valor Ordenado (Rol)
1	605
2	1446
3	1461
4	1685
5	1851
6	1944
7	1969
8	2077
9	2134
10	2402

Tabela 11: Valores ordenados para `total.user`.

$$\text{Mediana} = \frac{1851 + 1944}{2} = 1897.5$$

Para season2:

Posição	Valor Ordenado (Rol)
1	1536
2	1693
3	1865
4	2028
5	2077
6	2121
7	2210
8	2425
9	2496
10	2703

Tabela 12: Valores ordenados para `season2`.

$$\text{Mediana} = \frac{2077 + 2121}{2} = 2099$$

Para season3:

Posição	Valor Ordenado (Rol)
1	4507
2	4648
3	4708
4	4790
5	4835
6	4991
7	5202
8	5225
9	5305
10	5515

Tabela 13: Valores ordenados para **season3**.

$$\text{Mediana} = \frac{4835 + 4991}{2} = 4913$$

Para season4:

Posição	Valor Ordenado (Rol)
1	2395
2	2429
3	2918
4	3907
5	4120
6	4630
7	4839
8	5010
9	5202
10	5423

Tabela 14: Valores ordenados para **season4**.

$$\text{Mediana} = \frac{4120 + 4630}{2} = 4375$$

DESVIO PADRÃO:

Formula do desvio padrão amostral:

$$\sqrt{\frac{\sum (xi - \bar{x})^2}{n - 1}}$$

Ou seja:

$$s = \left\{ \left[\sum (xi - \bar{x})^2 \right] \frac{1}{n - 1} \right\}^{\frac{1}{2}}$$

Para season1:

$$s = \left\{ \left[(1461 - 1757,4)^2 + (1969 - 1757,4)^2 + (2402 - 1757,4)^2 + (1446 - 1757,4)^2 + (1851 - 1757,4)^2 + (2134 - 1757,4)^2 + (1685 - 1757,4)^2 + (1944 - 1757,4)^2 + (2077 - 1757,4)^2 + (605 - 1757,4)^2 \right] \frac{1}{10-1} \right\}^{\frac{1}{2}} \approx 501.77 \quad (1)$$

Para season2:

$$s = \left\{ \left[(2077 - 2115,4)^2 + (2703 - 2115,4)^2 + (2121 - 2115,4)^2 + (1865 - 2115,4)^2 + (2210 - 2115,4)^2 + (2496 - 2115,4)^2 + (1693 - 2115,4)^2 + (2028 - 2115,4)^2 + (2425 - 2115,4)^2 + (1536 - 2115,4)^2 \right] \frac{1}{10-1} \right\}^{\frac{1}{2}} \approx 362.23 \quad (2)$$

Para season3:

$$s = \left\{ \left[(4835 - 4972,6)^2 + (4507 - 4972,6)^2 + (4790 - 4972,6)^2 + (4991 - 4972,6)^2 + (5202 - 4972,6)^2 + (5305 - 4972,6)^2 + (4708 - 4972,6)^2 + (4648 - 4972,6)^2 + (5225 - 4972,6)^2 + (5515 - 4972,6)^2 \right] \frac{1}{10-1} \right\}^{\frac{1}{2}} \approx 327.58 \quad (3)$$

Para season4:

$$s = \left\{ \left[(2395 - 4087,3)^2 + (5423 - 4087,3)^2 + (5010 - 4087,3)^2 + (4630 - 4087,3)^2 + (4120 - 4087,3)^2 + (3907 - 4087,3)^2 + (4839 - 4087,3)^2 + (5202 - 4087,3)^2 + (2429 - 4087,3)^2 + (2918 - 4087,3)^2 \right] \frac{1}{10-1} \right\}^{\frac{1}{2}} \approx 1142.72 \quad (4)$$

BOX PLOT:




Figura 6: Boxplot de total user e da estação do ano para as amostras

Amostras.Low_usage

De forma análoga a questão 2 quando foi criado o `data_groupinho` a categoria `low_usage` de cada um dos grupos feitos para as amostras de cada estação foi redefinido de modo que foi calculado o primeiro quartil de cada um deles e caso o número de usuários totais do termo fosse menor que $Q1$ ele receberia `low_usage`.

Para `season1`:

Valor absoluto:

$$v1 = 1 + 0 + 0 + 1 + 1 + 1 + 0 + 0 + 0 + 1 = 3$$

Média(valor relativo):

$$\bar{x} = \frac{\sum xi}{n} = \frac{v1}{10} = 0.3$$

Para `season2`:

Valor absoluto:

$$v2 = 0 + 0 + 0 + 1 + 0 + 0 + 1 + 0 + 0 + 1 = 3$$

Média(valor relativo):

$$\bar{x} = \frac{\sum xi}{n} = \frac{v2}{10} = 0.3$$

Para `season3`:

Valor absoluto:

$$v3 = 0 + 0 + 0 + 0 + 0 + 0 + 0 + 0 + 0 + 0 = 0$$

Média(valor relativo):

$$\bar{x} = \frac{\sum xi}{n} = \frac{v3}{10} = 0$$

Para `season4`:

Valor absoluto:

$$v4 = 1 + 0 + 0 + 0 + 0 + 0 + 0 + 0 + 1 + 1 = 3$$

Média(valor relativo):

$$\bar{x} = \frac{\sum xi}{n} = \frac{v4}{10} = 0.3$$

Item 3.2

Neste item era necessário analisar o sistema para diferentes condições meteorológicas e calcular, por meio de códigos em R, a média e o desvio padrão de `total_user` para cada uma dessas condições obtendo assim as seguintes tabelas:

Condições meteorológicas	total_user
1	4172,522
2	3449,971
3	1757,571

Tabela 15: Média do número total de usuários por condição meteorológica.

Condições meteorológicas	total_user
1	946,6510
2	1102,6945
3	793,9503

Tabela 16: Desvio padrão do número total de usuários por condição meteorológica.

Low usage:

Nesta parte, de maneira similar a do item 3.1, foi feito um código em R para calcular a quantidade de dias com low usage (variável `low_usage` tanto em valor absoluto quanto em valor relativo, dessa forma temos as seguintes tabelas

Tabela 1:

Condições meteorológicas	Low_usage (valor absoluto)
1	25
2	36
3	14

Tabela 2:

Condições meteorológicas	Low_usage (valor relativo)
1	0.1358696
2	0.3529412
3	1.0000000

Ao analisar a tabela com os valores relativos de `low_usage` percebe-se que todos os dias da condição meteorológica 3 são considerados como `low_usage`, além disso, nela o sistema possui o menor número de `total_user` em média como mostra o gráfico de barras:




Figura 7: Gráfico de barras dos usuários totais por condições meteorológicas

Amostras

Para ser feita a amostragem da situação do tempo foram criados 3 data groups sendo eles: `data_groupinho_weathersit1`, `data_groupinho_weathersit2` e `data_groupinho_weathersit3` em que cada um deles engloba as 10 primeiras ocorrências da situação do tempo designada a eles. A partir deles foram feitos manualmente e de maneira computacional os cálculos da média e desvio padrão de `total_user` em cada situação do tempo.

MÉDIA:

Formula da média :

$$\bar{x} = \frac{\sum x_i}{n}$$

Para weathersit1:

$$\bar{x} = \frac{\sum x_i}{n} = \frac{1969 + 2402 + 1851 + 2134 + 1685 + 1872 + 2133 + 2132 + 2417 + 2046}{10} = 2064.1$$

Para weathersit2:

$$\bar{x} = \frac{\sum x_i}{n} = \frac{1461 + 1446 + 1944 + 2077 + 605 + 1891 + 1977 + 2056 + 2192 + 2077}{10} = 1772.6$$

Para weathersit3:

$$\bar{x} = \frac{\sum x_i}{n} = \frac{623 + 1685 + 795 + 2710 + 1996 + 1842 + 2416 + 2424 + 627 + 1817}{10} = 1693,5$$

Ou seja o valor das 3 médias correspondeu ao resultado do trecho de código correspondente a cada uma delas no apêndice e, além disso percebe-se que o valor da média da situação 3 é a menor dentre elas tanto com o conjunto total de dados quanto com as amostras.

DESVIO PADRÃO:

Formula do desvio padrão amostral:

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n - 1}}$$

Ou seja:

$$s = \left\{ \left[\sum (xi - \bar{x})^2 \right] \frac{1}{n-1} \right\}^{\frac{1}{2}}$$

Para weathersit1:

$$s = \left\{ \left[(1969 - 2064,1)^2 + (2402 - 2064,1)^2 + (1851 - 2064,1)^2 + (2134 - 2064,1)^2 + (1685 - 2064,1)^2 + (1872 - 2064,1)^2 + (2133 - 2064,1)^2 + (2132 - 2064,1)^2 + (2417 - 2064,1)^2 + (2046 - 2064,1)^2 \right] \frac{1}{10-1} \right\}^{\frac{1}{2}} \approx 232.94 \quad (5)$$

Para weathersit2:

$$s = \left\{ \left[(1461 - 1772,6)^2 + (1446 - 1772,6)^2 + (1944 - 1772,6)^2 + (2077 - 1772,6)^2 + (605 - 1772,6)^2 + (1891 - 1772,6)^2 + (1977 - 1772,6)^2 + (2056 - 1772,6)^2 + (2192 - 1772,6)^2 + (2077 - 1772,6)^2 \right] \frac{1}{10-1} \right\}^{\frac{1}{2}} \approx 482.33 \quad (6)$$

Para weathersit3:

$$s = \left\{ \left[(623 - 1693,5)^2 + (1685 - 1693,5)^2 + (795 - 1693,5)^2 + (2710 - 1693,5)^2 + (1996 - 1693,5)^2 + (1842 - 1693,5)^2 + (2416 - 1693,5)^2 + (2424 - 1693,5)^2 + (627 - 1693,5)^2 + (1817 - 1693,5)^2 \right] \frac{1}{10-1} \right\}^{\frac{1}{2}} \approx 768.01 \quad (7)$$

Assim como a média, os valores do código para o desvio padrão presente no apêndice estavam iguais aos valores feitos pelo cálculo manual.

GRÁFICO DE BARRA

Também foi feito um gráfico de barras para as amostras conforme a imagem abaixo:




Figura 8: Gráfico de barras das amostras dos usuários totais por condições meteorológicas

Amostras.Low_usage

Para manter-se uma consistência na forma como é calculado low_usage, assim como quando foi criado o data_groupinho na questão 2 e no item 3.1, houve uma redefinição no low_usage de cada um desses grupinhos de weathersit da mesma maneira que foi redefinido para o data_groupinho.

Desse modo, foram novamente calculadas a média de dias com low_usage, usada na frequência relativa, e a soma desses dias, usada na frequência absoluta, a partir da redefinição feita acima.

Para weathersit1:

Valor absoluto:

$$v1 = 0 + 0 + 1 + 0 + 1 + 1 + 0 + 0 + 0 + 0 = 3$$

Média(valor relativo):

$$\bar{x} = \frac{\sum xi}{n} = \frac{v1}{10} = 0.3$$

Para weathersit2:

Valor absoluto:

$$v2 = 1 + 1 + 0 + 0 + 1 + 0 + 0 + 0 + 0 + 0 = 3$$

Média(valor relativo):

$$\bar{x} = \frac{\sum xi}{n} = \frac{v2}{10} = 0.3$$

Para weathersit3:

Valor absoluto:

$$v3 = 1 + 0 + 1 + 0 + 0 + 0 + 0 + 0 + 1 + 0 = 3$$

Média(valor relativo):

$$\bar{x} = \frac{\sum xi}{n} = \frac{v3}{10} = 0.3$$

Item 3.3

Neste item, deve-se obter uma relação entre a temperatura e total_user por meio de um gráfico de dispersão feito em R, bem como calcular o coeficiente de correlação para, assim, interpretar a direção e a intensidade da associação e discutir possíveis limitações do coeficiente de correlação para descrever a relação observada.

Com o código localizado no apêndice, foi plotado o seguinte gráfico:




Figura 9: Gráfico de dispersão entre temp e total_user

Com o gráfico, observa-se uma tendência crescente, em que, no geral, quanto maior a temperatura maior é o número de total user. Sobre isso, pode-se imaginar que existe uma correlação entre as duas variáveis com um coeficiente positivo.

Coeficiente de correlação:

No R a partir da função "cor()" é possível calcular o coeficiente de correlação de um gráfico de dispersão utilizando os métodos de pearson, kendall e spearman cujos valores estão presentes na tabela abaixo:

Método usado	Coeficiente de correlação
Pearson	0.6386874
Kendall	0.429283
Spearman	0.6352908

A diferença entre os métodos consiste em que tipo de dados eles estão analisando já que o método de Pearson considera que os dados são lineares, enquanto tanto o método de Kendall quanto o de Spearman consideram relações não paramétricas, porém, devido a maneira em que são calculados, o método de Spearman é melhor para grandes amostras enquanto o de Kendall é melhor para pequenas.

Desse modo, o método mais adequado para ser levado em consideração seria o de Spearman pois a relação entre os dados não ocorre de maneira linear e o tamanho da amostra pode ser considerado grande.

Amostras

Para separar as 10 primeiras amostras da temperatura foi usado o data_groupinho da questão 2. A partir dele foi possível fazer um gráfico de dispersão para essas amostras, cujo código está no apêndice, além

disso foi calculado o coeficiente de correlação dessas amostra, por meio do método de Spearman, de forma manual e computacional.

Amostras: Gráfico de dispersão




Figura 10: Gráfico de dispersão de usuários totais e temperatura

Amostras: Cálculo do coeficiente de correlação

Como o método de Spearman foi o escolhido na parte do cálculo com o conjunto de dados por completo ele será o método que vai ser utilizado para gerar uma noção do coeficiente de correlação das amostras.

Para o método de Spearman:

$$r = 1 - \frac{6 \sum (d_i)^2}{n(n^2 - 1)}$$

Em que

$$d_i = Posto(x_i) - Posto(y_i)$$

O posto de um elemento é a posição dele se estivesse ordenado dentro de um conjunto de forma crescente, desse modo a tabela abaixo contém o posto de cada elemento x_i e y_i do gráfico de dispersão :

Portanto

$$r = 1 - \frac{6 \times 200}{10(10^2 - 1)} = \frac{990 - 1200}{990}$$

Ou seja $r = -0.2121$ manualmente enquanto o código usado no apêndice gerou como resultado -0.2121

Item 3.4

Este item tem como objetivo a escolha de 2 condições que parecem afetar mais o uso do sistema.

Dessa forma, analisando os dados obtidos a partir da resolução do item 3.2, percebe-se que a condição meteorológica afeta o uso do sistema de maneira considerável, pois todos os dias que estavam na condição meteorológica 3 são considerados low usage. Além disso, outro fator que parece ter afetado de maneira considerável o uso do sistema são as estações do ano, uma vez que a estação 1 tem 92% dos seus dias com low_usage e possui a menor média de total_user dentre todas as estações do ano.

Obs.	temp	total_user	Posto R_Y	Posto R_X	d_i	d_i^2
1	14.9	1461	7	3	-4	16
2	11.6	1969	4	7	3	9
3	14.1	2402	6	10	4	16
4	16.7	1446	10	2	-8	64
5	10.9	1851	3	5	2	4
6	13.7	2134	5	9	4	16
7	8.1	1685	1	4	3	9
8	10.7	1944	2	6	4	16
9	15.8	2077	9	8	-1	1
10	15.4	605	8	1	-7	49
Total	–	–	–	–	–	200

Questão 4

A questão tem o objetivo de, juntamente com os resultados obtidos nas Questões 2 e 3, aprofundar a análise do comportamento do sistema de compartilhamento de bicicleta.

Item 4.1

No primeiro item, deve ser contruída a série temporal de **total_user**. Em seguida, devem ser identificados os períodos de maior e menor utilização do sistema, discutindo os principais padrões observados.

Dessa forma, durante a primeira parte do código, foi criada a variável de série temporal de **total_user**, para isso usa-se a função **ts()**, que necessita da variável analisada (**total_user**), a data de início da análise (25/11/2011) e a frequência por ano com a qual a variável foi amostrada (uma amostra por dia, ou seja, 365 vezes por ano).

Sobre a data de início da análise, foi criada a variável **datas**, que compreende **data_group\$dteday** lido no formato de data (ano - mês - dia). Após, para calcular a data de início no formato necessário para a função **ts()**, foi criada a variável **dia_inicio**, a qual contém a data inicial em dia do ano (de 1 a 365/366).

Por fim, **dia_inicio** é usado na função **ts()** para determinar o início da análise como o 56º dia de 2011.

```

1 datas <- as.Date(data_group$dteday)
2
3 dia_inicio <- data_group$instant[1]
4
5 total_user_ts <- ts(data_group$total_user, start = c(2011, dia_inicio), freq =
  365)

```

item 4.1 - Construção da variável de série temporal

Na segunda parte, foi feita a plotagem da série temporal em si. Para isso, foi usada a função **plot()**, porém com o parâmetro **xaxt = "n"**, para personalizar os rótulos do eixo x.

Sobre a personalização, primeiro foi feita uma sequência (**marcadores_datas**) com as datas desejadas para marcação no eixo (de mês em mês, do início até o final da análise). Em seguida essas datas foram formatadas na estrutura desejada de mês/ano (**rotulos**). Ademais, foram calculadas as posições nas quais esses rótulos ficariam, por meio da fórmula:

$$\text{posição} = \text{ano} + \frac{\text{dia do ano} - 1}{365}$$

A qual calcula cada posição de modo igual à função **ts()**, fazendo a conta relativa à fração de passagem do ano.

Por fim, foi usada a função `axis()`, para colocar os nomes definidos (`labels = rotulos`) nas posições calculadas (`at = posicoes_rotulos`), no eixo x do gráfico (`side = 1`).

```
1 plot(total_user_ts,
2     xaxt = "n",
3     lwd = 2,
4     main = "Serie Temporal - Total de Usuarios",
5     xlab = "Ano",
6     ylab = "Total de Usuarios")
7
8 marcadores_datas <- seq(from = datas[1], to = max(datas), by = "1 month")
9
10 rotulos <- format(marcadores_datas, "%b/%Y")
11
12 posicoes_rotulos <- as.numeric(format(marcadores_datas, "%Y")) + (as.numeric(
13     format(marcadores_datas, "%j")) - 1) / 365
14
15 axis(side = 1, at = posicoes_rotulos, labels = rotulos)
```

Item 4.1 - Plotagem da série temporal




Figura 11: Gráfico da série temporal de `total_user`

Análise do gráfico:

Por meio da série temporal, é possível observar que o menor período de utilização do processo de compartilhamento de bicicletas ocorreu no início da análise (fevereiro de 2011), cuja maior parte dos dados está em torno dos 2000 usuários. Em seguida, o processo demonstrou crescimento no decorrer do ano, atingindo seu período de maior utilização entre os meses de maio e outubro, com seu pico por volta dos 6000 usuários.

Ademais, sobre os padrões da série, nota-se uma tendência de crescimento ao longo da primeira metade do período analisado (de fevereiro a junho), além de uma tendência decrescente na segunda metade (de julho a dezembro). Desse modo, considerando-se o contexto de análise anual, é possível assumir que os dados apresentam um comportamento cíclico de baixa e alta utilização durante, respectivamente, os meses do começo/final do ano e os meses do meio.

Item 4.2

No segundo item, deve-se retomar as duas características selecionadas na Questão 3 e, para cada uma, escolher uma visualização e uma medida estatística adequadas para analisar sua associação com `total_user`. Deve-se também apresentar e interpretar os resultados, além de compará-los com as conclusões obtidas na questão anterior.

As características escolhidas foram as **estações do ano (season)** e as **condições meteorológicas (weathersit)**.

ESTAÇÕES (season):

Para a primeira, notando-se a natureza qualitativa da variável `season` e quantitativa de `total_user`, para uma melhor visualização de sua associação, foi escolhido o gráfico de barras.

Dessa forma, no código, foram criadas as variáveis `user_inverno`, `user_primavera`, `user_verao` e `user_outono`, cada qual contendo apenas as quantidades de usuários dos dias das suas respectivas estações. Em seguida, foi plotado o gráfico de barras com a soma total dos usuários de cada estação:

```
1 user_inverno <- data_group$total_user[data_group$season==1]
2 user_primavera <- data_group$total_user[data_group$season==2]
3 user_verao <- data_group$total_user[data_group$season==3]
4 user_outono <- data_group$total_user[data_group$season==4]
5
6 options(scipen = 999) #desabilita a notacao cientifica para melhor visualizacao
  dos numeros do eixo y
7
8 barplot(c(sum(user_inverno), sum(user_primavera), sum(user_verao), sum(user_
  outono)),
9   names.arg = c("inverno (1)", "primavera (2)", "verao (3)", "outono (4)"),
10  col=c("skyblue", "pink", "orange", "brown"),
11  xlab="season",
12  ylab="total user",
13  main="total user x season")
```

Item 4.2 - plotagem do gráfico de barras das estações




Figura 12: Gráfico de barras entre `season` e `total_user`

Análise do gráfico:

Com o gráfico, nota-se que a maior quantidade de usos do processo de compartilhamento ocorreu no verão, e a menor, no inverno. Assim, esse resultado colabora com a observação da Questão 3 sobre a maior parte dos dias de inverno serem considerados `low_usage`, além de confirmar o comportamento observado na série temporal durante os meses do meio do ano (verão) e os meses do começo/final do ano (inverno).

CONDIÇÕES METEOROLÓGICAS (`weathersit`):

Para a segunda, novamente devido às naturezas das variáveis envolvidas (`weathersit` também é qualitativa), foi escolhido o gráfico de barras.

Desse modo, o código foi feito de maneira semelhante ao anterior. Logo, foram criadas as variáveis `user_weather1`, `user_weather2` e `user_weather3`, cada qual contendo apenas as quantidades de usuários dos dias das suas respectivas condições meteorológicas. Em seguida, foi plotado o gráfico de barras com a soma total dos usuários de cada condição:

```

1 user_weather1 <- data_group$total_user[data_group$weathersit==1]
2 user_weather2 <- data_group$total_user[data_group$weathersit==2]
3 user_weather3 <- data_group$total_user[data_group$weathersit==3]
4
5 barplot(c(sum(user_weather1), sum(user_weather2), sum(user_weather3)),
6         names.arg = c("1", "2", "3"),
7         col=c("skyblue", "orange", "grey"),
8         xlab="weathersit",
9         ylab="total user",
10        main="total user x weathersit")

```




Figura 13: Gráfico de barras entre `weathersit` e `total_user`

Análise do gráfico:

Com o gráfico, nota-se que foi durante dias de céu limpo (1) em que ocorreu a maioria das utilizações do processo de compartilhamento. Por outro lado, durante os dias de chuva fraca (3), ocorreu um número muito menor de usos. Assim, é possível fortalecer a observação inicial na Questão 3, pois existe uma grande discrepância entre a maior e a menor quantidade de utilizações entre as condições.

Item 4.3

O terceiro item tem o objetivo de aprofundar a análise da relação entre temperatura e `total_user`, diferenciando visualmente os dias classificados como `low_usage` dos restantes. Além disso, é necessário discutir os principais padrões observados e avaliar se a relação entre temperatura e utilização parece diferir entre os grupos.

Para isso, o primeiro quartil de `total_user` foi calculado mais uma vez e alocado na variável `quartil1_group`. Após, o gráfico de dispersão entre `total_user` e `temp` foi plotado novamente, porém dessa vez, foi adicionada uma linha vermelha tracejada (`lty = 2`) para melhor visualização dos pontos de `low_usage`.

Ademais, também foi plotada uma linha azul da média de `temp`, para uma análise mais profunda dos valores da temperatura nesses dias.

```
1 quartil1_group <- quantile(data_group$total_user, probs = 0.25)
2
3 plot(data_group$total_user, data_group$temp,
4       xlab = "Usuários totais",
```

```

5   ylab = "Temperatura (C)")
6
7   abline(v = quartil1_group, col = "red", lty = 2)
8
9   abline(h = mean(data_group$temp), col = "blue", lty = 2)

```

Item 4.3 - plotagem do gráfico de dispersão com linhas




Figura 14: Gráfico de dispersão entre `temp` e `total_user` com linhas

Análise do gráfico:

Por meio do gráfico, é possível visualizar mais facilmente que a maior parte dos dias classificados como `low_usage` possuem temperaturas abaixo da média, enquanto nos dias de maior utilização ocorre o contrário (em geral, eles apresentam maior temperatura). Entretanto, nos dias de maior uso do sistema, ocorre uma dispersão maior dos dados, entre os quais ocorre uma maior variação no número de usuários em um mesmo nível de temperatura, possivelmente indicando que existe uma maior quantidade de fatores decisivos para a quantidade de usuários após certa temperatura.

Assim, ainda se pode comprovar a tendência de crescimento no gráfico, indicando uma correlação positiva entre as duas variáveis.

Item 4.4

No último item, é pedido uma conclusão final sintetizando as principais análises, resultados e gráficos obtidos ao longo do trabalho, destacando quais características parecem estar mais associadas à utilização do sistema, sempre apresentando os valores relevantes e interpretando-os no contexto do problema.

Em síntese, a análise do sistema de compartilhamento de bicicletas foi realizada no conjunto de dados de 300 observações (`data_group`) e revela que a utilização diária total (`total_user`) apresenta forte

sensibilidade a fatores climáticos e sazonais. Ademais, a demanda média geral foi de aproximadamente 3814 usuários/dia (com mediana de 4.067,5).

Nesse contexto, uma das características mais fortemente associadas ao uso do sistema foi a condição meteorológica (weathersit), a qual apresenta grande impacto na demanda. Por exemplo, em dias de céu limpo (1), foi registrada uma média de 4172,5 usuários/dia, caindo para 3450 em dias nublados (2) e despencando para 1757,6 em dias de chuva fraca (3), a qual ainda teve 100% de seus dias classificados como de baixa utilização.

Outras características importantes foram a estação do ano (season) e a temperatura (temp), sobre as quais o verão (estação 3) apresentou o maior nível de uso, com média de 4464,4 usuários/dia. Por outro lado, o inverno (estação 1) concentrou 92% de seus dias como de baixa utilização, apresentando média de apenas 2045,8 usuários/dia. Essa forte associação positiva com a temperatura é confirmada pelo coeficiente de correlação de Spearman de $r=0,635$, indicando uma relação forte entre a elevação da temperatura e o aumento do número de usuários.

Por fim, as séries temporais e gráficos de dispersão confirmam um padrão cíclico anual, em que dias ensolarados e temperaturas amenas ou quentes impulsionam o uso, enquanto chuvas e temperaturas baixas são os principais fatores inibidores.

Apêndice: Código R Utilizado

Questão 1

```
1 data_orig <- read.csv("HW1_bike_sharing.csv")
2 matriculas <- c(582204, 590055, 582887, 582929)
3 M <- max(matriculas)
4 r <- 1 + (M %% 100)
5
6 data_group <- data_orig[r:(r + 299), ]
7 data_group$dteday[1]
8 data_group$dteday[300]
```

Seleção e construção do dataset do grupo (data_group)

Questão 2

```
1 data_group$total_user <- data_group$casual + data_group$registered
2 colSums(is.na(data_group))
```

Item 2.1 - Criação da variável total_user e verificação de valores ausentes

```
1 #Criação da miniamostra
2 data_groupinho <- data_group[1:10, ]
3
4 #media (sem na.rm pois ja nao tem dados ausentes, idem pros proximos)
5 colMeans(data_groupinho[, 6:9])
6 colMeans(data_group[, 6:9])
7
8 #mediana (existe uma biblioteca com um colMedians())
9
10 median(data_groupinho$temp)
11 median(data_groupinho$casual)
12 median(data_groupinho$registered)
13 median(data_groupinho$total_user)
14
15 median(data_group$temp)
16 median(data_group$casual)
17 median(data_group$registered)
18 median(data_group$total_user)
19
20 #criando e usando moda
21 moda <- function(d){
22   freq <- table(d)
23   valor_moda <- names(freq)[freq == max(freq)]
24   freq_moda <- max(freq)
25
26   cat("Moda:", valor_moda, "\n")
27   cat("Frequencia:", freq_moda, "\n")
28 }
29
30 moda(data_groupinho$season)
31 moda(data_groupinho$weathersit)
32
33 moda(data_group$season)
34 moda(data_group$weathersit)
```

2.2 - Criação de uma mini amostra com 10 observações para legitimação e as funções que calculam as medidas de tendência central

```

1 #quartil Q1, Q2 e Q3
2 quantile(data_groupinho$temp, probs = c(0.25, 0.5, 0.75))
3 quantile(data_groupinho$casual, probs = c(0.25, 0.5, 0.75))
4 quantile(data_groupinho$registered, probs = c(0.25, 0.5, 0.75))
5 quantile(data_groupinho$total_user, probs = c(0.25, 0.5, 0.75), type = 2)
6
7 quantile(data_group$temp, probs = c(0.25, 0.5, 0.75))
8 quantile(data_group$casual, probs = c(0.25, 0.5, 0.75))
9 quantile(data_group$registered, probs = c(0.25, 0.5, 0.75))
10 quantile(data_group$total_user, probs = c(0.25, 0.5, 0.75))
11
12 #intervalo interquartil
13 quartis_groupinho <- quantile(data_groupinho$total_user, probs = c(0.25, 0.5,
14 0.75))
15 Q1 <- quartis_groupinho[1]
16 Q3 <- quartis_groupinho[3]
17 IIQ <- unname(Q3 - Q1)
18 IIQ
19 # alternativamente (funcao propria do R):
20 IQR(data_groupinho$total_user)

```

2.3 - Código do cálculo dos quartis e do intervalo interquartil IIQ

```

1
2 library(ggplot2)
3
4 ggplot(data = data_groupinho) +
5   geom_histogram(mapping = aes(x = total_user), binwidth = NULL, bins = 30, fill
6     = "steelblue", color = "white") +
7   labs(
8     title = "Histograma do Valor de Clientes Totais",
9     x = "Valor de Clientes Totais",
10    y = "Frequencia"
11  )
12
13 ggplot(data = data_groupinho) +
14   geom_boxplot(mapping = aes(y = total_user), fill = "steelblue", color = "black"
15     ) +
16   labs(
17     title = "Boxplot do Valor de Clientes Totais",
18     y = "Valor de Clientes Totais"
19   )
20
21 ggplot(data = data_group) +
22   geom_histogram(mapping = aes(x = total_user), binwidth = NULL, bins = 30, fill
23     = "steelblue", color = "white") +
24   labs(
25     title = "Histograma do Valor de Clientes Totais",
26     x = "Valor de Clientes Totais",
27     y = "Frequencia"
28   )
29
30 ggplot(data = data_group) +
31   geom_boxplot(mapping = aes(y = total_user), fill = "steelblue", color = "black"
32     ) +
33   labs(
34     title = "Boxplot do Valor de Clientes Totais",
35     y = "Valor de Clientes Totais"
36   )

```

2.4 - Plotagem dos boxplots e dos histogramas

```

1 Q1 <- quantile(data_group$total_user, 0.25)
2 data_group$low_usage <- ifelse(data_group$total_user < Q1, 1, 0)
3 baixa_utilizacao <- sum(data_group$low_usage)
4 proporcao <- mean(data_group$low_usage)
5
6 # Exibir resultados no console
7 Q1
8 baixa_utilizacao
9 proporcao

```

Item 2.5 - Verificação da quantidade de dados abaixo do quartil 1

Questão 3

```

1 #Calculo da media
2 aggregate(total_user~season, data=data_group, FUN=mean)
3
4 #Calculo da mediana
5 aggregate(total_user~season, data=data_group, FUN=median)
6
7 #Calculo do desvio padrao
8 aggregate(total_user~season, data=data_group, FUN=sd)
9
10 #Calculo do numero de dias com low usage dentro das estacoes em quantidade
    absoluta e em relativa
11 aggregate(low_usage~season, data=data_group, FUN=sum)
12 aggregate(low_usage~season, data=data_group, FUN=mean)
13
14 #Construcao do boxplot
15 boxplot(total_user~season, data=data_group, col="skyblue")
16
17 #Criacao das amostras
18 data_groupincho_season1 <- data_groupincho # Como groupinho tem 10 casos da
    estacao 1 entao serve para ser analisado
19 data_groupincho_season2 <- head(data_group[data_group$season == 2, ], 10)
20 data_groupincho_season3 <- head(data_group[data_group$season == 3, ], 10)
21 data_groupincho_season4 <- head(data_group[data_group$season == 4, ], 10)
22
23 #Calculo das medias das amostras
24 aggregate(total_user~season, data=data_groupincho_season1, FUN=mean) #para season 1
25 aggregate(total_user~season, data=data_groupincho_season2, FUN=mean) #para season 2
26 aggregate(total_user~season, data=data_groupincho_season3, FUN=mean) #para season 3
27 aggregate(total_user~season, data=data_groupincho_season4, FUN=mean) #para season 4
28
29 #Calculo das medianas das amostras
30 aggregate(total_user~season, data=data_groupincho_season1, FUN=median) #para season
    1
31 aggregate(total_user~season, data=data_groupincho_season2, FUN=median) #para season
    2
32 aggregate(total_user~season, data=data_groupincho_season3, FUN=median) #para season
    3
33 aggregate(total_user~season, data=data_groupincho_season4, FUN=median) #para season
    4
34
35 #Calculo do desvio padrao das amostras
36 aggregate(total_user~season, data=data_groupincho_season1, FUN=sd) #para season 1
37 aggregate(total_user~season, data=data_groupincho_season2, FUN=sd) #para season 2
38 aggregate(total_user~season, data=data_groupincho_season3, FUN=sd) #para season 3
39 aggregate(total_user~season, data=data_groupincho_season4, FUN=sd) #para season 4

```

```

40
41 #Construcao do box plot das amostras
42 boxplot(data_groupinho_season1$total_user,data_groupinho_season2$total_user,data
_groupinho_season3$total_user,data_groupinho_season4$total_user,names=c("1",
"2","3","4"),col="skyblue",xlab="season",ylab="total user")
43
44 #Etapas feitas para redefinir low_usage de forma adequada em cada uma das
amostras
45 Q1_amostra_season1<-quantile(data_groupinho_season1$total_user, 0.25) # calculo
do primeiro quartil (Q1) de total_user na amostra de season 1
46 data_groupinho_season1$low_usage<-ifelse(data_groupinho_season1$total_user < Q1_
amostra_season1, 1, 0) #Valores que estao abaixo de Q1 recebem 1, se nao,
recebem 0
47 Q1_amostra_season2<-quantile(data_groupinho_season2$total_user, 0.25) # calculo
do primeiro quartil (Q1) de total_user na amostra de season 2
48 data_groupinho_season2$low_usage<-ifelse(data_groupinho_season2$total_user < Q1_
amostra_season2, 1, 0) #Valores que estao abaixo de Q1 recebem 1, se nao,
recebem 0
49 Q1_amostra_season3<-quantile(data_groupinho_season3$total_user, 0.25) # calculo
do primeiro quartil (Q1) de total_user na amostra de season 3
50 data_groupinho_season3$low_usage<-ifelse(data_groupinho_season3$total_user < Q1_
amostra_season2, 1, 0) #Valores que estao abaixo de Q1 recebem 1, se nao,
recebem 0
51 Q1_amostra_season4<-quantile(data_groupinho_season4$total_user, 0.25) # calculo
do primeiro quartil (Q1) de total_user na amostra de season 4
52 data_groupinho_season4$low_usage<-ifelse(data_groupinho_season4$total_user < Q1_
amostra_season4, 1, 0) #Valores que estao abaixo de Q1 recebem 1, se nao,
recebem 0
53
54 #Calculo do numero de dias com low usage dentro das estacoes em quantidade
absoluta e em relativa para as amostras
55 aggregate(low_usage~season,data=data_groupinho_season1,FUN=sum) #calculo do
valor absoluto de low usage na amostra de season 1
56 aggregate(low_usage~season,data=data_groupinho_season1,FUN=mean) #calculo do
valor relativo de low usage na amostra de season 1
57 aggregate(low_usage~season,data=data_groupinho_season2,FUN=sum) #calculo do
valor absoluto de low usage na amostra de season 2
58 aggregate(low_usage~season,data=data_groupinho_season2,FUN=mean) #calculo do
valor relativo de low usage na amostra de season 2
59 aggregate(low_usage~season,data=data_groupinho_season3,FUN=sum) #calculo do
valor absoluto de low usage na amostra de season 3
60 aggregate(low_usage~season,data=data_groupinho_season3,FUN=mean) #calculo do
valor relativo de low usage na amostra de season 3
61 aggregate(low_usage~season,data=data_groupinho_season4,FUN=sum) #calculo do
valor absoluto de low usage na amostra de season 4
62 aggregate(low_usage~season,data=data_groupinho_season4,FUN=mean) #calculo do
valor relativo de low usage na amostra de season 4

```

Item 3.1

```

1 #Calculo da media
2 aggregate(total_user~weathersit,data=data_group,FUN=mean)
3
4 #Calculo do desvio padrao
5 aggregate(total_user~weathersit,data=data_group,FUN=sd)
6
7 #Coleta do numero de dias com low usage para cada condicao de tempo
8 aggregate(low_usage~weathersit,data=data_group,FUN=sum)
9
10 #Fazendo os parametros do grafico de barras a partir dos dados obtidos
anteriormente

```

```

11 Media1 <- 4172.522
12 Media2 <- 3449.971
13 Media3 <- 1757.571
14
15 #Criando o grafico de barras
16 barplot(c(Media1,Media2,Media3),names.arg=c("1","2","3"),col=c("orange","skyblue",
17   "","grey"),xlab= "Condicoes Metereologicas ",ylab="Media de total user",main=
18   "Media de total user por condicao metereologica")
19
20 #Criacao das amostras
21 data_groupinho_weathersit1 <- head(data_group[data_group$weathersit == 1, ], 10)
22 data_groupinho_weathersit2 <- head(data_group[data_group$weathersit == 2, ], 10)
23 data_groupinho_weathersit3 <- head(data_group[data_group$weathersit == 3, ], 10)
24
25 #Calculo das medias das amostras
26 aggregate(total_user~weathersit,data=data_groupinho_weathersit1,FUN=mean) # para
27   weathersit1
28 aggregate(total_user~weathersit,data=data_groupinho_weathersit2,FUN=mean) # para
29   weathersit2
30 aggregate(total_user~weathersit,data=data_groupinho_weathersit3,FUN=mean) # para
31   weathersit3
32
33 #Calculo do desvio padrao
34 aggregate(total_user~weathersit,data=data_groupinho_weathersit1,FUN=sd) # para
35   weathersit1
36 aggregate(total_user~weathersit,data=data_groupinho_weathersit2,FUN=sd) # para
37   weathersit2
38 aggregate(total_user~weathersit,data=data_groupinho_weathersit3,FUN=sd) # para
39   weathersit3
40
41 #Valores necessarios para construir o grafico
42 Media_groupinho1 <- mean(data_groupinho_weathersit1$total_user)
43 Media_groupinho2 <- mean(data_groupinho_weathersit2$total_user)
44 Media_groupinho3 <- mean(data_groupinho_weathersit3$total_user)
45
46 #Criacao do grafico de barras
47 barplot(c(Media_groupinho1,Media_groupinho2,Media_groupinho3),names.arg=c("1","2",
48   "","3"),col=c("skyblue","orange","grey"),xlab="Condicoes meteorologicas",ylab
49   ="Media de total user",main="Media de total user por condicao meteorologica"
50   )
51
52 #Correcao de low usage para cada um dos grupos
53 Q1_amostra_weathersit1<-quantile(data_groupinho_weathersit1$total_user, 0.25) #
54   calculo do primeiro quartil (Q1) de total_user na amostra de weathersit 1
55 data_groupinho_weathersit1$low_usage<-ifelse(data_groupinho_weathersit1$total_
56   user < Q1_amostra_weathersit1, 1, 0) #Valores que estao abaixo de Q1 recebem
57   1, se nao, recebem 0
58 Q1_amostra_weathersit2<-quantile(data_groupinho_weathersit2$total_user, 0.25) #
59   calculo do primeiro quartil (Q1) de total_user na amostra de weathersit 2
60 data_groupinho_weathersit2$low_usage<-ifelse(data_groupinho_weathersit2$total_
61   user < Q1_amostra_weathersit2, 1, 0) #Valores que estao abaixo de Q1 recebem
62   1, se nao, recebem 0
63 Q1_amostra_weathersit3<-quantile(data_groupinho_weathersit3$total_user, 0.25) #
64   calculo do primeiro quartil (Q1) de total_user na amostra de weathersit 3
65 data_groupinho_weathersit3$low_usage<-ifelse(data_groupinho_weathersit3$total_
66   user < Q1_amostra_weathersit3, 1, 0) #Valores que estao abaixo de Q1 recebem
67   1, se nao, recebem 0
68
69 #Coleta do numero de dias com low usage para cada condicao de tempo das amostras
70 aggregate(low_usage~weathersit,data=data_groupinho_weathersit1,FUN=sum) # valor
71   absoluto de low usage na amostra de weathersit 1

```

```

51 aggregate(low_usage~weathersit,data=data_groupinho_weathersit1,FUN=mean) # valor
    relativo de low usage na amostra de weathersit 1
52 aggregate(low_usage~weathersit,data=data_groupinho_weathersit2,FUN=sum) # valor
    absoluto de low usage na amostra de weathersit 2
53 aggregate(low_usage~weathersit,data=data_groupinho_weathersit2,FUN=mean) # valor
    relativo de low usage na amostra de weathersit 2
54 aggregate(low_usage~weathersit,data=data_groupinho_weathersit3,FUN=sum) # valor
    absoluto de low usage na amostra de weathersit 3
55 aggregate(low_usage~weathersit,data=data_groupinho_weathersit3,FUN=mean) # valor
    relativo de low usage na amostra de weathersit 3

```

Item 3.2

```

1 #Criacao do grafico de dispersao
2 plot(data_group$total_user,data_group$temp,xlab="total user",ylab="temperatura")
3
4 #Calculo do coeficiente de correlacao utilizando 3 metodos diferentes
5 cor(data_group$total_user,data_group$temp,method ="pearson") # calcula
    considerando como se os dados fossem lineares
6 cor(data_group$total_user,data_group$temp,method ="kendall")#calcula para
    relacoes nao parametricas
7 cor(data_group$total_user,data_group$temp,method ="spearman")# calcula para
    casos ordinais ou que possuam outliers
8
9 #Criacao do grafico de dispersao da amostra
10 plot(data_groupinho$total_user,data_groupinho$temp,xlab="total user",ylab="
    temperatura")
11
12 #Calculo do coeficiente de correlacao da amostra utilizando 3 metodos diferentes
13 cor(data_groupinho$total_user,data_groupinho$temp,method ="pearson") # calcula
    considerando como se os dados fossem lineares
14 cor(data_groupinho$total_user,data_groupinho$temp,method ="kendall")#calcula
    para relacoes nao parametricas
15 cor(data_groupinho$total_user,data_groupinho$temp,method ="spearman")# calcula
    para casos ordinais ou que possuam outliers

```

Item 3.3

Questão 4

```

1 #Criacao da variavel de serie temporal
2 datas <- as.Date(data_group$dteday)
3
4 dia_inicio <- data_group$instant[1]
5
6 total_user_ts <- ts(data_group$total_user, start = c(2011, dia_inicio), freq =
    365)
7
8 #Plotagem do grafico da serie temporal
9 plot(total_user_ts,
10      xaxt = "n",
11      lwd = 2,
12      main = "Serie Temporal - Total de Usuarios",
13      xlab = "Ano",
14      ylab = "Total de Usuarios")
15
16 #Personalizacao do eixo x do grafico
17 marcadores_datas <- seq(from = datas[1], to = max(datas), by = "1 month")
18
19 rotulos <- format(marcadores_datas, "%b/%Y") #formato %b %Y --> Ex.: fev 2011

```

```

20
21 posicoes_rotulos <- as.numeric(format(marcadores_datas, "%Y")) + (as.numeric(
    format(marcadores_datas, "%j")) - 1) / 365
22
23 axis(side = 1, at = posicoes_rotulos, labels = rotulos)

```

Item 4.1

```

1 #Divisao de total_user entre as estacoes
2 user_inverno <- data_group$total_user[data_group$season==1]
3 user_primavera <- data_group$total_user[data_group$season==2]
4 user_verao <- data_group$total_user[data_group$season==3]
5 user_outono <- data_group$total_user[data_group$season==4]
6
7 #Desabilitacao da notacao cientifica para melhor visualizacao dos numeros do
  eixo y
8 options(scipen = 999)
9
10 #Plotagem do grafico de barras das estacoes
11 barplot(c(sum(user_inverno), sum(user_primavera), sum(user_verao), sum(user_
    outono)),
12   names.arg = c("inverno (1)", "primavera (2)", "verao (3)", "outono (4)"),
13   col=c("skyblue", "pink", "orange", "brown"),
14   xlab="season",
15   ylab="total user",
16   main="total user x season")
17
18 #Divisao de total_user entre as condicoes meteorologicas
19 user_weather1 <- data_group$total_user[data_group$weathersit==1]
20 user_weather2 <- data_group$total_user[data_group$weathersit==2]
21 user_weather3 <- data_group$total_user[data_group$weathersit==3]
22
23 #Plotagem do grafico de barras das condicoes meteorologicas
24 barplot(c(sum(user_weather1), sum(user_weather2), sum(user_weather3)),
25   names.arg = c("1", "2", "3"),
26   col=c("skyblue", "orange", "grey"),
27   xlab="weathersit",
28   ylab="total user",
29   main="total user x weathersit")

```

Item 4.2

```

1 #Criacao da variavel que contem Q1
2 quartil1_group <- quantile(data_group$total_user, probs = 0.25)
3
4 #Plotagem do grafico igual 3.3
5 plot(data_group$total_user, data_group$temp,
6   xlab = "Usuarios totais",
7   ylab = "Temperatura (C)")
8
9 #Adicao das linhas de visualizacao
10 abline(v = quartil1_group, col = "red", lty = 2)
11
12 abline(h = mean(data_group$temp), col = "blue", lty = 2)

```

Item 4.3